

Politechnika Wrocławska

Wydział Informatyki i Telekomunikacji

Kierunek: Informatyczne Systemy Automatyki
Specjalność: Zastosowania Technologii Informacyjnych

Projekt przejściowy

Zastosowanie algorytmów uczenia maszynowego do oceny
degeneracyjnych zmian kręgosłupa lędźwiowego na podstawie
obrazów MRI

Autor:

Jakub Skwierczyński

Prowadzący:

Dr inż. Michał Piórek

Wrocław 2025

Spis treści

1	Wstęp	3
2	Badania	4
2.1	Opis zbioru danych	4
2.2	Wstępne przetwarzanie danych	4
2.3	Implementacja modeli	6
2.4	Walidacja i ocena modeli	7
3	Wnioski i plany rozwoju	9

Spis rysunków

2.1	Znormalizowane obrazy MRI w płaszczyźnie strzałkowej z zaznaczonymi obszarami patologicznymi.	5
2.2	Przykładowy tensor o głębokości 18.	5
2.3	Przykładowy wykres funkcji straty dla modelu 3D CNN podczas klasyfikacji binarnej na tensorze $18 \times 96 \times 96$.	7

Spis tabel

1	Liczność klas dla każdej choroby w zbiorze testowym	8
2	Podsumowanie wyników walidacji modeli na zbiorze testowym	8

1. Wstęp

Ból dolnej części pleców jest jedną z głównych przyczyn niepełnosprawności na świecie. Według Światowej Organizacji Zdrowia (WHO) w 2020 roku dotyczył on aż 619 milionów osób. Większość ludzi doświadcza tego rodzaju bólu w pewnym momencie swojego życia, a jego częstotliwość wzrasta wraz z wiekiem. Ból oraz ograniczenie ruchomości to często objawy spondylozy – zespołu degeneracyjnych schorzeń kręgosłupa, obejmujących m.in. degenerację krążków międzykręgowych, zwężenie kanału kręgowego (stenoza kręgosłupa), zwężenie podartykularne oraz otworów nerwowych, co prowadzi do kompresji lub podrażnienia nerwów w dolnej części pleców [1].

Celem projektu jest opracowanie i walidacja modeli uczenia maszynowego do automatycznej identyfikacji i oceny degeneracyjnych zmian kręgosłupa lędźwiowego na podstawie obrazów z rezonansu magnetycznego. Proponowane rozwiązanie ma szansę znacząco wspierać proces diagnostyczny zarówno w ortopedii jak i reumatologii.

2. Badania

2.1. Opis zbioru danych


Zbiór danych wykorzystany w badaniach pochodzi z konkursu RSNA 2024 i obejmuje obrazy rezonansu magnetycznego (MRI) kręgosłupa lędźwiowego w formacie DICOM. Zbiór obejmuje 1975 badań, zawierających łącznie 147218 zdjęć MRI. Dane zawierają pięć klas zmian degeneracyjnych kręgosłupa, takich jak zwężenie kanału kręgowego (Spinal Canal Stenosis) czy zwężenie otworów nerwowych (Neural Foraminal Narrowing). Dla każdego badania MRI przypisano etykiety opisujące stopień zaawansowania zmian (Normal/Mild, Moderate, Severe) oraz współrzędne lokalizacji tych zmian w obrazach. Zbiór danych został podzielony na część treningową oraz testową. Szczegółowe informacje dotyczące danych można znaleźć na stronie konkursu Kaggle: Kaggle RSNA 2024 Lumbar Spine Degenerative Classification.

2.2. Wstępne przetwarzanie danych

Proces wstępnego przetwarzania danych obejmował kilka etapów, mających na celu przygotowanie obrazów MRI do analizy przez modele uczenia maszynowego. Najważniejsze kroki obejmowały:


- **Filtrację danych:** Wybrano jedynie obrazy odpowiadające poziomowi kręgu docelowego L4/L5.
- **Pobranie wymiarów obrazów DICOM:** Dla każdego obrazu określono jego wymiary (wysokość i szerokość), co umożliwiło dalsze skalowanie i normalizację.
- **Normalizację intensywności pikseli:** Intensywności pikseli zostały ograniczone do zakresu [1%, 99%], a następnie znormalizowane do przedziału [0, 1].
- **Skalowanie i przycinanie:** Obrazy zostały przeskalowane do rozmiaru 512×512 , a następnie przycięte w okolicach współrzędnych zmian patologicznych na podstawie specyficznych marginesów zdefiniowanych w konfiguracji.

- **Interpolacja trójwymiarowa:** Sekwencje obrazów dla jednego badania zostały wyrównane do różnej liczby przekrojów (głębokość $D = 32$, $D = 18$, $D = 1$), a następnie przeskalowane do rozmiaru 96×96 .
- **Zapis do formatu Tensor:** Przetworzone dane zostały zapisane w postaci tensorów PyTorch, co umożliwiło ich bezpośrednie wykorzystanie w modelach uczenia maszynowego.



Rysunek 2.1: Znormalizowane obrazy MRI w płaszczyźnie strzałkowej z zaznaczonymi obszarami patologicznymi.

Na rysunku 2.1 przedstawiono przykładowe obrazy MRI kręgosłupa w płaszczyźnie strzałkowej, na których zaznaczono obszary patologiczne za pomocą prostokąta w kolorze żółtym. Punkty w kolorze czerwonym wskazują dokładne współrzędne centralne zmian patologicznych, zidentyfikowanych w danych źródłowych.



Rysunek 2.2: Przykładowy tensor o głębokości 18.

Na rysunku 2.2 zaprezentowano wynikowy tensor zawierający 18 wyciętych przekrojów obrazów MRI przeskalowanych do rozmiaru 96×96 . Każdy przekrój reprezentuje

kolejne warstwy obrazu w badaniu, a cały tensor umożliwia modelowi uczenia maszynowego analizę przestrzennych zależności pomiędzy kolejnymi warstwami.

2.3. Implementacja modeli

W celu analizy danych MRI opracowano różne modele głębokich sieci neuronowych, uwzględniając różne głębokości tensorów oraz specyficzne architektury dostosowane do charakterystyki danych. Modele umożliwiają klasyfikację dwóch patologii: *zwężenia kanału kręgowego (spinal canal stenosis)* oraz *zwężenia otworów międzykręgowych (neural foraminal narrowing)* w odcinku L4/L5. Do analizy opracowano następujące architektury:


- **2D CNN** – model wykorzystujący pojedyncze przekroje (96×96) do analizy obrazów MRI,
- **3D CNN** – model uwzględniający przestrzenne zależności w danych w postaci tensora 3D ($18 \times 96 \times 96$),
- **3D CNN + LSTM** – model łączący analizę przestrzenną z modelowaniem sekwencyjnym, wykorzystując tensor 3D ($32 \times 96 \times 96$),
- **3D CNN + BiLSTM + Attention** – model wykorzystujący dwukierunkowy LSTM oraz mechanizmy uwagi do analizy głębokich cech w tensorze 3D ($64 \times 96 \times 96$).

Wszystkie modele zostały zaimplementowane jako klasyfikatory wieloklasowe i wieloetykietowe, gdzie dla każdej patologii przewidywane są trzy poziomy nasilenia:

- **0 (Normal/Mild)** – stan normalny lub łagodny,
- **1 (Moderate)** – umiarkowane nasilenie,
- **2 (Severe)** – ciężkie nasilenie.

Dodatkowo, dla każdej patologii przeprowadzono klasyfikację binarną, w której uwzględniono dwa stany:

- **0 (Brak patologii lub łagodna)** – stan normalny lub łagodny,
- **1 (Umiarkowana lub ciężka)** – stan umiarkowany lub ciężki.



Rysunek 2.3: Przykładowy wykres funkcji straty dla modelu 3D CNN podczas klasyfikacji binarnej na tensorze $18 \times 96 \times 96$.

Na rysunku 2.3 przedstawiono wykres funkcji straty dla zbiorów treningowego i walidacyjnego podczas trenowania modelu 3D CNN. Widoczny przebieg wskazuje na brak oznak przeuczenia modelu, ponieważ wartości funkcji straty dla zbiorów treningowego i walidacyjnego są zbliżone i stabilizują się w kolejnych epokach.

2.4. Walidacja i ocena modeli

Zbiór testowy stanowił 10% całego zbioru danych i obejmował łącznie 198 próbek. Szczegóły dotyczące liczności klas znajdują się w tabeli 1.

Tabela 1: Liczność klas dla każdej choroby w zbiorze testowym

Choroba	Klasa	Liczność (Support)	Łączna liczność
SCS	Normalna/Mild	149	198
	Moderate	24	
	Severe	25	
NFN	Normalna/Mild	89	198
	Moderate	86	
	Severe	22	

Ze względu na niezbalansowanie danych wybrano zbiorczą metrykę *weighted avg.* Metryka ta uwzględnia licznosc próbek w poszczególnych klasach, co pozwala na bardziej miarodajną ocenę skuteczności modelu w przypadku niezrównoważonych danych.

Tabela 2: Podsumowanie wyników walidacji modeli na zbiorze testowym

Model	Choroba	Rodzaj klasyfikacji	Głębokość tensora	Precision	Recall	F1-score
2D CNN	SCS	Wieloklasowa	1	0.7538	0.8586	0.8026
2D CNN	NFN	Wieloklasowa	1	0.4962	0.5657	0.5204
3D CNN + BiLSTM + Attention	SCS	Wieloklasowa	18	0.8280	0.8485	0.8229
3D CNN + BiLSTM + Attention	NFN	Wieloklasowa	18	0.5570	0.6162	0.5816
3D CNN + BiLSTM + Attention	SCS	Wieloklasowa	32	0.5663	0.7525	0.6463
3D CNN + BiLSTM + Attention	NFN	Wieloklasowa	32	0.5594	0.6313	0.5888
3D CNN	SCS	Binarna	18	0.9387	0.9394	0.9385
3D CNN	NFN	Binarna	18	0.6845	0.6717	0.6719

W tabeli 2 przedstawiono wyniki walidacji modeli w postaci metryk *Precision*, *Recall* oraz *F1-score* dla dwóch klasyfikowanych patologii: SCS (Spinal Canal Stenosis, zwężenie kanału kręgowego) oraz NFN (Neural Foraminal Narrowing, zwężenie otworów międzykręgowych).

3. Wnioski i plany rozwoju

Analiza wyników przedstawionych w tabeli 2 wskazuje, że klasyfikacja *Spinal Canal Stenosis (SCS)* (zwężenie kanału kręgowego) została przeprowadzona znacznie skuteczniej niż klasyfikacja *Neural Foraminal Narrowing (NFN)* (zwężenie otworów międzykręgowych). Model 3D CNN, w szczególności zastosowany do binarnej klasyfikacji SCS, osiągnął najwyższe wartości metryk *Precision*, *Recall* oraz *F1-score*.

Z kolei wyniki dla klasyfikacji NFN są wyraźnie gorsze. Głównym powodem tego jest niższa jakość danych przypisanych do etykiety NFN. Zdjęcia MRI z etykietami NFN charakteryzują się niższą rozdzielczością oraz większym poziomem szumu, co znacząco utrudnia modelom uczenia maszynowego skuteczne rozpoznawanie i klasyfikację tej patologii. Dodatkowo, liczba próbek w poszczególnych klasach jest niezbalansowana, co dodatkowo negatywnie wpływa na wyniki klasyfikacji.

Podsumowując, zastosowanie przestrzennych modeli 3D CNN okazało się najbardziej efektywne w analizie danych MRI, szczególnie dla patologii SCS. Wyniki klasyfikacji NFN wskazują jednak na konieczność dalszej pracy nad poprawą jakości danych oraz optymalizacją modeli.

W ramach dalszych prac planowane są następujące kroki:

- **Analiza hiperparametrów:** Zostanie przeprowadzona analiza wpływu hiperparametrów, takich jak głębokość tensora, liczba warstw sieci, funkcje aktywacji oraz współczynniki uczenia, na skuteczność modeli.
- **Eksploracja metod głębokiego uczenia:** Planowane jest przetestowanie dostępnych architektur głębokich sieci neuronowych, w celu zwiększenia jakości klasyfikacji.

Literatura

- [1] World Health Organization. "WHO releases guidelines on chronic low back pain." 2023. Dostępne online: <https://www.who.int/news/item/07-12-2023-who-releases-guidelines-on-chronic-low-back-pain>.
- [2] Merali, Z., Wang, J. Z., Badhiwala, J. H., et al. A deep learning model for detection of cervical spinal cord compression in MRI scans. *Scientific Reports*, 2021.
- [3] Abuhayi, B. M., Bezabh, Y. A., Ayalew, A. M. Lumbar Disease Classification Using an Involutional Neural Based VGG Nets. *IEEE Access*, 2024.
- [4] Wang, T., Chen, R., Fan, N., et al. Machine Learning and Deep Learning for Diagnosis of Lumbar Spinal Stenosis. *J Med Internet Res*, 2024.
- [5] Liawrungrueang, W., Kim, P., et al. Automatic Detection, Classification, and Grading of Lumbar Intervertebral Disc Degeneration. *Diagnostics*, 2023.